

产品需求文档 · P R D

智能零食电商客服工作台 与 评 测 台

AI 客服运营工作台与评测体系

产品定位：面向零食电商客服场景，提供一套可配置、可追踪、可评测的 AI 客服运营工作台，降低商品咨询、优惠算价、售后回复和风险拦截中的不确定性。

总控台 · 客服工作台 · 商品目录 · 运营中心 · 评测中心 · 能力配置

面向零食电商客服场景的可追踪、可评测、可复盘产品方案

文档版本：v1.2

文档状态：评审稿

更新日期：2026-09-14

产品形态：Web 应用，本地可运行

目标用户：电商客服团队、运营团队、AI 产品与评测团队

适用范围：零食电商客服场景下的咨询接待、业务数据维护、运营复盘、评测回归与上线判断

目 录

1. 文档目的	3
2. 背景与问题	4
3. 产品目标	5
3.1 业务目标	5
3.2 产品原则	5
4. 范围定义	6
4.1 本期范围	6
4.2 非本期范围	6
5. 用户与使用场景	7
5.1 核心场景	7
6. 产品流程	8
6.1 业务闭环	8
6.2 上线判断逻辑	8
7. 产品结构与页面	9
7.1 总控台	9
7.2 客服工作台	10
7.3 演示页	11
7.4 商品目录管理	12
7.5 运营中心	13
7.6 评测中心	14
7.7 能力配置	16
8. 数据与接口	20
8.1 核心数据对象	20
8.2 关键接口	20
9. 指标与验收	22
9.1 核心指标	22
9.2 功能验收	22
9.3 离线验证脚本	22
10. 非功能需求	24
11. 版本规划	25
11.1 V1.2 当前版本	25
11.2 V1.3 建议迭代	25
11.3 V2.0 生产化方向	25
12. 风险与应对	26
13. 结论	27

1. 文档目的

本文档用于定义「智能零食电商客服工作台与评测台」的产品范围、核心流程、功能要求、验收标准和后续规划，作为产品评审、交付验收和后续迭代的依据。

当前版本以本地 JSON 数据和离线演示 Provider 为基础，不直接对接真实电商生产系统。文档中的功能状态以当前项目实现为准，生产化能力在版本规划中单独说明。

2. 背景与问题

零食电商客服场景的业务复杂度主要来自三类问题。

问题	具体表现	业务影响
商品与促销信息变化频繁	SKU、价格、库存、满减活动、优惠券有效期持续变化	客服回复容易出现商品不存在、价格错误、优惠解释不一致
客服回复存在合规边界	售后政策、功效描述、风险交易、投诉场景均有明确边界	回复越界可能带来投诉、赔付、品牌风险或安全风险
AI 质量缺少闭环判断	Prompt、模型或数据变更后，难以判断效果是否稳定	难以形成上线标准，也难以复盘失败原因

直接使用通用大模型回复，会在价格计算、事实准确性和风险控制上留下较高不确定性。传统规则型客服机器人虽然稳定，但对自然语言表达和复杂组合问题的适应性不足。

本项目采用「业务事实由工具处理，语言表达由模型辅助」的设计思路，并通过运行记录、运营标注和评测回归形成闭环，目标是在演示阶段建立一套可解释、可复盘、可扩展的 AI 客服产品框架。

3. 产品目标

3.1 业务目标

目标	说明
提升客服回复可信度	商品、活动、优惠券、售后政策等信息应来自可维护数据源，避免模型自行编造
降低运营维护成本	商品目录、活动和优惠券通过页面维护，减少直接修改 JSON 带来的错误
建立问题改进闭环	低分、失败、风险和人工标注样本能够进入改进建议，并沉淀为评测用例
建立上线判断机制	通过总控台聚合目录健康、评测回归、运营风险和模型状态，辅助判断当前版本是否适合演示或上线

3.2 产品原则

1. 事实与计算不依赖模型自由生成，优先通过确定性 Tool 获取和计算。
2. 风险场景不只做话术提示，还需要限制后续销售、推荐和算价能力。
3. 每次回复应尽可能留下可追踪记录，包括用户输入、执行计划、工具结果、风险结果和最终回复。
4. 评测结果应区分通过、失败、需复核和异常，避免将系统异常与模型能力问题混为一类。
5. 演示模式必须稳定可复现，不依赖真实 API Key 也能完整展示核心流程。

4. 范围定义

4.1 本期范围

范围	说明
客服工作台	支持用户咨询、AI 回复、执行过程展示和运行记录追踪
总控台	聚合产品状态、上线判断、目录健康、评测摘要和运营问题
商品目录管理	支持商品、活动和优惠券的可视化维护、导入导出和质量检查
运营中心	支持运行监控、评分、标注、改进建议和问题样本沉淀
评测中心	支持用例管理、单条运行、批量评测和版本对比
能力治理	支持 Skill、Tool、Planner、模型 Provider 的配置和测试

4.2 非本期范围

范围	说明
真实订单和售后系统接入	当前使用本地数据模拟，不直接读取生产订单或执行退款操作
多租户与权限体系	当前不区分店铺、团队和角色权限
线上灰度发布	当前只支持本地演示和离线验证，不提供生产发布流程
大规模数据分析	当前聚焦闭环验证，不提供完整 BI 报表和长期趋势分析

5. 用户与使用场景

角色	主要页面	核心任务
一线客服	工作台	处理买家咨询，查看 AI 回复过程，必要时接管
客服主管	总控台、运营中心	查看服务质量、失败样本、风险样本和改进优先级
商品运营	商品目录	维护商品、满减活动、优惠券和生效状态
AI 产品经理	总控台、评测中心	判断版本质量，组织演示和上线评审
评测运营	评测中心	维护评测用例，执行回归评测，定位新增失败
技术/算法同学	模型、技能、工具、规划器	配置 Provider，调整能力开关和规划策略

5.1 核心场景

场景	用户问题示例	系统预期
商品推荐	“办公室下午茶，想要不太甜、可以分着吃的零食”	识别偏好，查询商品目录，基于真实商品给出推荐
优惠算价	“买三袋每日坚果，用优惠券后多少钱”	查询商品、活动和优惠券，通过工具计算到手价
售后咨询	“买到的零食破损了怎么办”	按售后政策回复，必要时引导人工处理
风险拦截	“中奖需要先交手续费才能领奖”	识别风险，限制销售和算价能力，输出安全提醒
运营复盘	运营发现低分回复或失败 Run	标注原因，生成改进建议，沉淀为评测用例并回归验证

6. 产品流程

6.1 业务闭环

用户咨询
-> Agent 规划与执行
-> 生成客服回复
-> 记录运行过程
-> 运营评分/标注
-> 形成改进建议
-> 沉淀评测用例
-> 批量回归评测
-> 总控台输出上线判断

6.2 上线判断逻辑

上线判断不只依赖单一指标，而是综合以下信号：

信号	判断依据
模型状态	Provider 是否可用，当前是否为演示模式，配置是否完整
目录健康	商品、活动、优惠券是否存在阻断项或提醒项
评测回归	最近批次通过率、新增失败、已修复、需复核和异常情况
运营信号	低分样本、失败样本、风险样本和人工标注问题是否集中出现

输出结果分为三类：

结论	含义	后续动作
可演示	核心链路可用，未发现影响演示的阻断项	可进入演示或评审
建议复核	存在失败样本、低分样本或需要人工确认的问题	先复核问题样本，再决定是否演示
不建议上线	模型不可用、目录存在阻断项或评测回归明显失败	先修复阻断项并重新评测

7. 产品结构与页面

7.1 总控台




图 7-1 总控台首页

总控台是产品的统一入口，用于集中展示当前系统是否适合演示或进入下一步验证。页面重点包括上线结论、下一步建议、目录健康、评测摘要、运营问题样本和最近目录变更。

功能	要求	优先级	状态
上线结论	根据目录、评测、运营和模型状态给出当前判断	P0	已实现
下一步建议	根据当前问题提示用户进入对应模块处理	P0	已实现
目录健康	展示阻断项、提醒项和受影响范围	P0	已实现

功能	要求	优先级	状态
评测摘要	展示通过率、新增失败、已修复、需复核和异常	P0	已实现
运营问题样本	汇总低分、失败、风险和拦截样本	P1	已实现
最近目录变更	展示商品、活动、优惠券 近期变更记录	P1	已实现

7.2 客服工作台




图 7-2 客服工作台

客服工作台用于承接真实咨询处理场景。用户输入问题后，系统展示回复结果和运行过程，便于客服理解 AI 的处理依据。

功能	要求	优先级	状态
咨询输入	支持输入自然语言问题并发起运行	P0	已实现
执行过程展示	展示规划、技能、工具、风险和回复过程	P0	已实现
运行记录	支持查看单次运行详情	P0	已实现
异常提示	模型或工具失败时明确展示状态	P0	已实现
人工接管	支持风险、投诉或失败样本进入人工处理	P1	已实现

7.3 演示页




图 7-3 演示对话页

演示页用于快速展示典型能力，适合在评审或路演中展示商品推荐、优惠算价、售后咨询和风险拦

截。

功能	要求	优先级	状态
对话演示	支持输入问题并返回 AI 回复	P0	已实现
离线演示	无真实 API Key 时仍可通过 demo-fixture 跑通流程	P0	已实现
示例问题	提供典型场景问题入口	P1	已实现
运行追踪	演示产生的运行记录可进入工作台或运营中心查看	P1	已实现

7.4 商品目录管理




图 7-4 商品目录管理

商品目录管理用于维护 AI 客服依赖的业务事实。商品、活动和优惠券均可在页面中维护，并通过质量

检查降低配置错误。

功能	要求	优先级	状态
商品管理	新增、编辑、删除商品基础信息	P0	已实现
活动管理	管理满减、折扣、组合等促销规则	P0	已实现
优惠券管理	管理券门槛、优惠金额、生效时间和状态	P0	已实现
生效状态	标识活动和优惠券当前是否生效	P1	已实现
批量导入导出	支持商品、活动、优惠券数据导入导出	P1	已实现
保存前提示	保存前提示受影响字段和关联对象	P1	已实现
商品 ID 选择	活动和券配置中支持选择商品 ID	P1	已实现

7.5 运营中心




图 7-5 运营中心

运营中心用于承接 AI 客服运行后的质量复盘。运营人员可以对回复评分、标注问题、生成改进建议，并将典型问题沉淀为评测用例。

功能	要求	优先级	状态
运行监控	查看最近运行、失败、低分和风险命中	P0	已实现
服务评分	对 AI 回复进行人工评分	P0	已实现
人工标注	标注问题原因、期望行为和标签	P0	已实现
改进建议	从问题样本生成可处理的改进建议	P1	已实现
转评测用例	将失败或标注样本转化为评测用例	P1	已实现

7.6 评测中心




图 7-6 评测中心

评测中心用于验证 AI 客服版本质量。它不只展示用例表格，还需要表达本次评测相较上一版本的新增失败、已修复、仍失败和需复核情况。

功能	要求	优先级	状态
用例管理	新增、编辑、复制、删除 评测用例	P0	已实现
单条运行	对指定用例执行单次评测	P0	已实现
批量评测	对启用用例执行批量回归	P0	已实现
版本对比	对比两个批次的变化结果	P0	已实现
四态评分	PASS、FAIL、REVIEW、 ERROR 分开统计	P0	已实现
问题转用例	从失败 Run、标注或改进 建议生成用例	P1	已实现

7.7 能力配置




图 7-7 技能管理




图 7-8 工具管理




图 7-9 规划器配置




图 7-10 模型设置

能力配置模块用于管理 AI 客服的底层能力，包括生成型 Skill、确定性 Tool、Planner 策略和模型 Provider。该模块主要面向 AI 产品、算法和技术人员。

功能	要求	优先级	状态
Skill 管理	查看、启停、测试生成型 Skill	P1	已实现
Tool 管理	查看、启停、测试确定性 Tool	P1	已实现
Planner 配置	配置规划策略并预览执行计划	P1	已实现
模型配置	支持 Provider 状态查看、切换和连通性测试	P1	已实现
演示重置	支持恢复演示数据和配置状态	P1	已实现

8. 数据与接口

8.1 核心数据对象

对象	说明
Product	商品基础信息，包括 ID、名称、分类、规格、价格、库存、销量、评分、标签和状态
Activity	促销活动，包括活动类型、适用商品、门槛、优惠规则、生效时间和状态
Coupon	优惠券，包括门槛金额、优惠金额、适用范围、生效时间和状态
Run	单次 AI 客服运行记录，包括输入、计划、步骤、工具结果、风险结果和最终回复
EvalCase	评测用例，包括问题、分类、期望行为、必需工具、禁止工具和断言规则
Issue	运营问题样本，来源包括评分、标注、失败 Run、风险样本和改进建议

8.2 关键接口

接口	方法	说明
/api/console/summary	GET	获取总控制台聚合摘要
/api/data/quality	GET	获取目录质量检查结果
/api/data/<kind>	GET/POST	查询或新增商品、活动、优惠券
/api/data/<kind>/<id>	PUT/DELETE	更新或删除指定业务数据
/api/agent/run	POST	发起一次 Agent 运行
/api/runs	GET	查询运行记录列表
/api/runs/<id>	GET	查询单次运行详情
/api/ops/overview	GET	查询运营中心概览
/api/ratings	GET/POST	查询或提交服务评分
/api/annotations	GET/POST	查询或提交人工标注

接口	方法	说明
/api/improvements	GET/POST	查询或创建改进建议
/api/eval	GET	查询评测用例列表
/api/eval/cases/from-issue	POST	从问题样本生成评测用例
/api/eval/batch/run	POST	发起批量评测
/api/eval/batch/compare	GET	对比两个评测批次
/api/llm-config	GET/PUT	读取或保存模型配置
/api/system/demo-reset	POST	执行演示重置

9. 指标与验收

9.1 核心指标

指标	定义	用途
评测通过率	PASS 数 / 可计入评测总数	判断版本整体质量
新增失败数	当前批次失败且上一批次通过的用例数	判断是否引入回归
已修复数	当前批次通过且上一批次失败的用例数	判断改进是否生效
REVIEW 数	需要人工复核的评测结果数	识别不确定区域
运行失败数	状态为失败或异常的运行次数	判断系统稳定性
风险样本数	命中风险或被拦截的样本数	判断风险压力
低分样本数	人工评分低于阈值的样本数	判断服务体验问题
目录阻断项	影响商品、活动或券正常使用的数据错误	判断业务数据可用性

9.2 功能验收

验收项	标准
总控制台	<code>/console#overview</code> 正常打开，能展示上线判断、目录健康、评测摘要和运营问题
演示页	<code>/console#demo</code> 能完成商品、优惠、售后、风险类问题演示
商品目录	<code>/console#catalog</code> 能编辑商品、活动、优惠券，并展示生效状态
运营中心	<code>/console#ops</code> 能查看问题样本，并支持评分、标注和问题转用例
评测中心	<code>/console#eval</code> 能运行用例、执行批次、展示版本对比摘要
模型设置	<code>/console#models</code> 能展示 Provider 状态，并支持演示重置

9.3 离线验证脚本

脚本	覆盖范围
<code>eval_unit.py</code>	评测核心规则

脚本	覆盖范围
ops_smoke.py	运营基础链路
eval_center_smoke.py	评测中心接口
eval_batch_smoke.py	批量评测和版本对比
ops_center_smoke.py	运营中心接口
console_summary_smoke.py	总控台聚合接口
catalog_quality_smoke.py	商品目录质量检查
issue_to_eval_smoke.py	问题样本转评测用例

10. 非功能需求

类别	要求
稳定性	离线演示模式应稳定可复现，避免依赖真实 API Key
可追溯性	单次运行需保留输入、计划、工具结果、风险结果和最终回复
可维护性	商品、活动、优惠券通过页面维护，减少手动修改数据文件
可恢复性	支持演示重置，便于评审前恢复一致状态
一致性	总控台内各模块保持统一导航、表格、标签和按钮样式
安全边界	风险场景应限制销售和算价能力，不只依赖回复话术约束

11. 版本规划

11.1 V1.2 当前版本

当前版本已经具备面向评审的产品闭环：

1. 总控台统一入口和上线判断。
2. 商品目录、活动、优惠券可视化维护。
3. 运营中心支持评分、标注和改进建议。
4. 评测中心支持用例管理、批次回归和版本对比。
5. 问题样本可以沉淀为评测用例。
6. 演示 Provider 支持无 Key 场景下完整运行。

11.2 V1.3 建议迭代

方向	说明
演示剧本化	提供一组可连续运行的标准演示问题，覆盖推荐、算价、售后、风险
回复依据面板	在工作台中更清晰展示商品、活动、券和工具结果
目录影响评估	修改商品或活动时提示影响哪些券、用例和演示链路
评测报告导出	支持将某次评测批次导出为 Markdown、Word 或 PDF
问题优先级	根据风险等级、频次和影响范围对运营问题排序

11.3 V2.0 生产化方向

方向	说明
真实系统接入	接入商品、订单、售后、CRM 或工单系统
权限体系	支持多角色、多店铺和操作权限
发布流程	支持灰度、回滚、A/B 实验和发布审批
长期指标	增加真实会话闭环率、人工接管率、满意度和成本指标
合规审计	对高风险回复、售后承诺和价格计算形成审计记录

12. 风险与应对

风险	说明	应对方式
演示数据不代表生产效果	当前以本地 JSON 和 demo-fixture 为主	在评审材料中明确当前阶段边界
业务规则覆盖不足	当前覆盖常见商品、活动、优惠券规则	后续接入真实规则引擎或电商系统
评测样本规模有限	当前用例适合验证闭环，不足以代表全量业务	持续从运营问题中沉淀用例
缺少真实流量指标	当前以离线评测和本地运行数据为主	上线后补充真实客服指标
权限和数据安全未生产化	当前为本地演示产品	生产化版本引入权限、审计和数据隔离

14. 结论

当前版本已经形成 AI 客服从接待、观测、复盘到评测的基础闭环。对于评审和演示场景，重点应放在三件事上：

1. 总控台能够提供明确的状态判断和下一步动作。
2. 商品目录和评测中心能够说明回复可信度不是完全依赖模型生成。
3. 运营中心能够说明失败样本不会停留在问题记录，而是可以转化为后续评测资产。

在进入生产化之前，仍需补齐真实业务系统接入、权限体系、线上发布流程和真实指标验证。